

Санкт-Петербургский государственный университет

Искусственный интеллект и наука о данных

Мазоватов Савелий Евгеньевич

Исследование применения мультимодальных языковых моделей к
задаче визуального понимания сложных таблиц

Отчет о прохождении

Учебной (ознакомительной) практики

Научный руководитель:

Старший преподаватель кафедры информатики СПбГУ Ф.В. Бушмелёв

Консультант:

Младший научный сотрудник ЛПИИ СПб ФИЦ РАН Д.А. Демиденко

Санкт-Петербург

2026

Оглавление

Оглавление

ОГЛАВЛЕНИЕ.....	2
1 ВВЕДЕНИЕ.....	3
1.1 Цель ПРАКТИКИ	4
1.2 Задачи.....	4
ГЛАВА 2. ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ.....	5
2.1 ЗАДАЧИ ОБРАБОТКИ ТАБЛИЧНЫХ ДАННЫХ	5
2.1.1 <i>Table Detection (TD) и Table Structure Recognition (TSR)</i>	5
2.1.2 <i>Table Question Answering (TQA)</i>	6
2.1.3 <i>Table-to-Text и Table Summarization</i>	6
2.1.4 <i>Table Fact Verification (TFV)</i>	6
2.2 ПРЕДСТАВЛЕНИЯ ТАБЛИЦ.....	7
2.2.1 <i>Сериализация</i>	7
2.2.2 <i>Представление в виде схемы данных</i>	8
2.2.3 <i>Форматы на основе изображений</i>	8
2.3 VISUAL-LANGUAGE MODELS	9
2.3.1 <i>Мультимодальная система на примере LLaVA-1.5</i>	9
2.3.2 <i>Ограничения LLaVA-подобных моделей при работе с таблицами</i>	10
2.3.3 <i>Qwen2.5-VL как пример развития VLM-архитектур</i>	11
2.3.4 <i>Проблема дорогого attention при увеличении разрешения</i>	12
2.3.5 <i>GLM-OCR в качестве примера специализированной OCR-модели для документов</i>	12
ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНАЯ УСТАНОВКА	14
3.1 НАБОР ДАННЫХ.....	14
3.2 ПОДСЧЕТ МЕТРИКИ.....	16
3.3 ФОРМАТ ПРОВЕДЕНИЯ ИСПЫТАНИЙ	16
ГЛАВА 4. ИССЛЕДОВАНИЕ.....	17
4.1 ОБЩИЕ РЕЗУЛЬТАТЫ	17
4.2 ОСНОВНЫЕ СЛОЖНОСТИ, АНАЛИЗ ХИТМАПОВ.....	19
4.2.1 <i>GLM-OCR</i>	19
4.2.2 <i>Qwen</i>	20
4.2.3 <i>Сравнение моделей</i>	21
ЗАКЛЮЧЕНИЕ.....	22
СПИСОК ЛИТЕРАТУРЫ.....	24

1 Введение

Таблицы являются одним из наиболее распространённых способов представления структурированной информации. Они используются в научных статьях, отчётах, финансовых документах, образовательных материалах, веб-страницах и PDF-документах. В отличие от обычного текста, таблица хранит информацию не только в виде последовательности слов и чисел, но и через двумерную структуру: строки, столбцы, заголовки, объединённые ячейки, визуальные группы и связи между элементами. [1, 2]

Автоматическая обработка таблиц является важной задачей в области искусственного интеллекта, поскольку многие прикладные системы должны уметь извлекать данные из документов, отвечать на вопросы по таблицам, проверять утверждения, строить краткие описания и преобразовывать таблицы в удобный для анализа формат. Однако таблицы остаются сложным объектом для моделей машинного обучения. Даже если модель успешно распознаёт текст внутри ячеек, этого недостаточно для полноценного понимания таблицы. Необходимо также восстановить её логическую структуру: определить, какие значения относятся к одним и тем же строкам и столбцам, где находятся заголовки, как устроены иерархические группы и как связаны отдельные элементы. [2, 4]

В последние годы для обработки таблиц всё чаще применяются большие языковые модели и мультимодальные языковые модели. Языковые модели могут работать с таблицами после их преобразования в текстовый формат, например Markdown, HTML, CSV или JSON. Такой подход удобен, но при сериализации часть визуальной и структурной информации может быть потеряна. Альтернативный подход заключается в использовании изображения таблицы и мультимодальной модели, которая способна анализировать одновременно визуальные данные и текстовую инструкцию пользователя. [1, 3]

В рамках данной работы рассматривается задача визуального понимания сложных таблиц с использованием мультимодальных языковых моделей. Особое внимание уделяется тому, насколько такие модели способны не только распознавать текст, но и восстанавливать структуру таблицы по изображению. В теоретической части рассматриваются основные задачи обработки таблиц, способы представления табличных данных и архитектурные особенности Vision-Language Models. В практической части проводится экспериментальная проверка способности современных моделей анализировать изображения таблиц разной сложности.

Актуальность работы связана с тем, что многие реальные документы содержат сложные таблицы: с мелким шрифтом, большим количеством строк и столбцов, объединёнными ячейками, многоуровневыми заголовками и нестандартным визуальным оформлением. Такие таблицы трудно корректно обработать только с помощью OCR или простой текстовой сериализации. Поэтому важно исследовать, насколько современные мультимодальные модели подходят для задач visual table understanding и какие ограничения сохраняются при их применении. [2, 4]

1.1 Цель практики

Целью работы является анализ устойчивости мультимодальных языковых моделей к изменению графического оформления сложных таблиц, включая линовку, цветовое кодирование и форматирование ячеек.

1.2 Задачи

1. Сформировать на основе PubTabNet тестовый набор таблиц с разными вариантами визуального оформления через CSS-стили для проверки устойчивости моделей к изменению внешнего вида табличных данных.
2. Реализовать программный модуль для инференса моделей GLM-OCR и Qwen2.5-VL, позволяющий восстанавливать HTML-разметку таблицы по изображению при разных параметрах входного разрешения и ограничения на число генерируемых токенов.
3. Провести сравнительный анализ GLM-OCR и Qwen2.5-VL, оценить влияние визуального стиля таблицы на качество восстановления HTML-структуры и определить основные ограничения моделей с использованием метрики TEDS.
4. Проанализировать наиболее сложные случаи распознавания с помощью хитмапов и выделить типы таблиц, на которых модели чаще всего допускают ошибки.

Глава 2. Обзор предметной области

2.1 Задачи обработки табличных данных

В этой секции будут представлены основные задачи, связанные с обработкой табличных данных. Сначала будут рассмотрены задачи, направленные на обнаружение и восстановление структуры таблицы: **Table Detection (TD)** и **Table Structure Recognition (TSR)**. Затем будут описаны задачи понимания таблиц (**Table Understanding, TU**), такие как **Table Question Answering (TQA)**, **Table-to-Text**, **Query Focused Summarization** и **Table Fact Verification (TFV)**. [1, 3]

2.1.1 Table Detection (TD) и Table Structure Recognition (TSR)

Table Detection — процесс, направленный на определение наличия и точного положения таблицы в документе или на изображении. Основная цель TD — не интерпретировать содержимое таблицы, а обозначить границы табличной области в пространстве документа. [2]

Если TD отвечает на вопрос расположения таблицы, то TSR идёт глубже. **Table Structure Recognition** нацелен на понимание внутренней разметки, организации и отношений компонентов внутри таблицы. Распознавание структуры является ключевым для любых последующих задач извлечения, преобразования или интерпретации данных. [2]

С TD и TSR связано множество трудностей, например: широкий диапазон форм, размеров и стилей таблиц; разные контексты их появления; разные типы информации; искажения или перекрытия другими объектами.

Хотя модели сегментации способны достаточно точно находить таблицы, классические методы машинного обучения имеют гораздо более выраженные недостатки. Основной сложностью распознавания таблицы является большое количество элементов на очень маленьком пространстве. В классических подходах компьютерного зрения часто применялось преобразование Хафа — метод для поиска геометрических объектов на изображении.

В TSR выделяются два фундаментальных аспекта:

1. **physical structure recognition** — распознавание физической структуры: расположение ячеек, строк, столбцов, границ элементов таблицы;
2. **logical structure recognition** — распознавание логической структуры: какие ячейки являются заголовками, какие строки и столбцы связаны, есть ли иерархия.

Таким образом, TD и TSR можно рассматривать как предварительные задачи, которые позволяют получить из документа или изображения табличную область и её структуру. После этого становятся возможны задачи более высокого уровня,

связанные уже не только с распознаванием таблицы, но и с её содержательным пониманием.

2.1.2 Table Question Answering (TQA)

Table Question Answering (TQA) является одной из самых распространённых и хорошо изученных задач понимания таблиц. Обычно на вход модели подаются таблица и вопрос на естественном языке. В ответе ожидаются данные из ячеек, вычисленные значения или минимальное текстовое описание. [1, 3]

Недавние работы достигают насыщения качества на широко используемых бенчмарках. Современные методы достигают более 80% точности на популярном датасете WikiTableQuestions. Высокая точность обусловлена ограниченностью множества бенчмарков: вначале генерируется SQL-запрос, который далее переводится в вопрос на естественном языке и подаётся на вход модели. [1]

В недавней работе [14] был представлен более комплексный подход к тестированию. Проверяется способность модели выявлять значимые закономерности, прогнозировать, создавать графики, основываясь на неоднозначных запросах. Эти направления исследуются в датасете Spider 2.0. [15]

2.1.3 Table-to-Text и Table Summarization

Table-to-Text и **Table Summarization** — задачи, разработанные для оценки способности модели понимать и описывать табличные данные. Обычно на вход подаётся таблица и, при необходимости, область ячеек, на которой модели следует сфокусироваться. Если ячейки не заданы, то требуется описать всю таблицу.

С развитием способности моделей понимать структуру данных эти задачи становятся менее актуальными, а количество публикаций постепенно снижается с 2021 года.

Query Focused Summarization — задача, смежная с предыдущими, но более актуальная в настоящее время. Наиболее популярным бенчмарком является QTSUMM [16], который требует от модели генерировать текстовые саммари конкретных областей таблицы в ответ на вопросы. В таком тестировании совмещаются задачи TQA и Table Summarization.

2.1.4 Table Fact Verification (TFV)

Table Fact Verification — задача, предназначенная для оценки способности модели находить факты и выполнять логические умозаключения. Входом являются утверждение на естественном языке и таблица. Выходом служит одна из меток: **Supported**, **Refuted** или **Not Enough Information**, указывающая на достоверность утверждения.

Современные методы позволяют моделям достичь более 80% точности на бенчмарках TabFact и FEVEROUS, однако такие модели всё ещё недостаточно проверены на более сложных сценариях. [1]

2.2 Представления таблиц

Поскольку большинству языковых моделей на вход требуется линейный формат данных, двумерные таблицы должны быть соответствующим образом преобразованы. Однако такое преобразование часто приводит к потере ценной структурной информации: связей между строками и столбцами, иерархии заголовков, объединённых ячеек и визуальных признаков. [1, 3]

Для решения этой проблемы были разработаны различные способы представления таблиц, включая сериализацию, представление в виде схемы данных, форматы на основе изображений и другие подходы. Недавние исследования показывают, что качество модели сильно зависит от выбранного входного представления таблицы. [17]

2.2.1 Сериализация

Сериализация является крайне распространённым способом представления табличных данных. Большинство современных бенчмарков опирается именно на неё. В этом подходе таблица преобразуется в линейный текстовый формат, который может быть обработан обычной языковой моделью. [1, 3]

Преобразование таблицы в сериализованный текст имеет явные преимущества:

1. совместимость со стандартными языковыми моделями;
2. лёгкий доступ к уже существующим форматам;
3. возможность использовать HTML- или Markdown-таблицы из открытых источников;
4. возможность использовать LaTeX-таблицы из PDF-документов.

Однако у сериализации есть и существенные ограничения. Длинные входы или входы с несколькими таблицами создают трудности из-за ограничений на длину контекста модели. Это часто приводит к обрезанию и потере части данных. [1, 3]

Чтобы справиться с ограничениями длины входа, были разработаны методы семплирования. Наиболее успешные из них — **centroid sampling** и **semantic-based sampling**. Они позволяют выбрать из таблицы наиболее важные строки или фрагменты, которые затем передаются модели.

Ещё один недостаток сериализации заключается в возможной потере структурной информации. При преобразовании таблицы в линейный текст хуже сохраняются связи между строками, столбцами, заголовками и отдельными ячейками. Особенно заметна эта проблема для сложных таблиц: с объединёнными ячейками, многоуровневыми заголовками и вложенными значениями. [1, 3]

2.2.2 Представление в виде схемы данных

Передача структуры таблицы вместо всего её содержимого также является распространённым вариантом представления данных. В этом случае модель получает не полную таблицу, а её структурное описание.

Наиболее распространённые варианты такого представления:

1. SQL-схема базы данных;
2. pandas DataFrame;
3. названия столбцов;
4. типы данных;
5. связи между таблицами, например primary keys и foreign keys.

Преимущество такого подхода заключается в том, что модель может не обрабатывать всю таблицу целиком, а работать только с её структурным описанием. Это помогает обходить ограничения на длину входа, особенно если таблица содержит большое количество строк.

Однако подход, основанный на схеме, хорошо работает в основном для строго структурированных таблиц. Как и в случае с сериализацией, модели чувствительны к формату схемы и к её оформлению. Например, Zhang et al. (2023a) [17] показали, что включение трёх строк в качестве примера позволяет значительно повысить качество работы модели.

Это связано с тем, что названия столбцов и типы данных не всегда полностью объясняют содержимое таблицы. Несколько примеров строк помогают модели лучше понять смысл данных и корректнее интерпретировать структуру таблицы.

2.2.3 Форматы на основе изображений

Изображение таблицы — ещё один важный способ представления табличных данных, особенно для мультимодальных моделей. В этом случае таблица подаётся не как текстовая сериализация или схема, а как визуальный объект: скриншот, изображение из PDF-документа или отрендеренная HTML-таблица. [1, 3]

Преимущества такого подхода:

1. сохраняется исходная структура таблицы;
2. модель видит границы ячеек, отступы, выравнивание и визуальные группы;
3. сохраняются цвет, размер шрифта и другие элементы форматирования;
4. такой подход хорошо подходит для VLM.

В недавней работе Zheng et al. (2024) [18] показали, что использование изображений вместе с дообученной LLaVA-моделью может давать лучшие результаты, чем подходы с OCR и текстовой сериализацией. OCR, или **Optical Character Recognition**, — это технология распознавания текста на изображении.

Однако у визуального представления есть и явные ограничения. Главное из них связано с разрешением изображения. Если таблица большая или содержит много мелких ячеек, то при фиксированном размере изображения информация становится менее читаемой. В результате модель может хуже распознавать текст, терять мелкие детали и ошибаться при сопоставлении ячеек, строк и столбцов. [2, 4]

Следовательно, представление таблицы в виде изображения лучше сохраняет визуальную структуру, но сильнее зависит от качества рендера, разрешения и способности мультимодальной модели работать с мелкими деталями.

2.3 Visual-Language Models

Vision-Language Models (VLM) — это класс мультимодальных моделей, предназначенных для совместной обработки изображений и текста. Такие модели получают на вход визуальную информацию, текстовую инструкцию пользователя и генерируют текстовый ответ. [8, 11]

В контексте обработки таблиц VLM особенно важны, поскольку таблица часто существует не только как структурированный текстовый объект, но и как визуальный объект: скриншот, изображение из PDF-документа или отрендеренная HTML-таблица. Поэтому для задач Table Detection (TD), Table Structure Recognition (TSR) и последующего Table Understanding (TU) важно учитывать не только текст внутри ячеек, но и пространственную организацию таблицы.

2.3.1 Мультимодальная система на примере LLaVA-1.5

Одним из наиболее известных примеров Vision-Language Models является **LLaVA** — **Large Language and Vision Assistant**. Эта модель показывает типичный подход к построению современных мультимодальных языковых моделей: вместо обучения всей системы с нуля используются уже предварительно обученные компоненты. [8, 11]

Архитектура LLaVA состоит из трёх основных частей: [8, 11]

1. визуального энкодера;
2. проекционного слоя;
3. большой языковой модели.

На рисунке показана общая схема работы модели:

X_v — входное изображение,

X_q — текстовая инструкция пользователя.




Figure 1 LLaVA модель

Входное изображение размером 336×336 разбивается на патчи размером 14×14 . Каждый патч разворачивается в вектор и преобразуется в embedding. Полученная последовательность визуальных эмбеддингов подаётся на вход предварительно обученной модели CLIP ViT, которая выступает в роли визуального энкодера. На выходе визуального энкодера формирует набор визуальных признаков изображения Z_v . [9, 10]

Далее признаки Z_v передаются в блок **Projection**. Projection — это многослойный перцептрон, который переводит эмбеддинги из пространства признаков CLIP в пространство, совместимое с языковой моделью Vicuna. На выходе получается набор визуальных токенов H_v , которые уже могут быть поданы в LLM вместе с текстовой инструкцией пользователя.

Модель Vicuna — это языковая модель, построенная на базе LLaMA от Meta и дополнительно дообученная для диалогового взаимодействия. В архитектуре LLaVA она отвечает за интерпретацию текстовой инструкции, обработку визуальных токенов и генерацию ответа. [12]

Поэтому, LLaVA можно представить как систему, в которой визуальный энкодер извлекает признаки изображения, projection слой переводит их в формат языковой модели, а LLM использует эти признаки вместе с текстовой инструкцией для генерации ответа.

2.3.2 Ограничения LLaVA-подобных моделей при работе с таблицами

Несмотря на удобную и достаточно эффективную архитектуру, LLaVA-подобные модели имеют ряд ограничений при работе с изображениями таблиц. Основная проблема связана с тем, что модель изначально строилась как универсальный визуальный ассистент, а не как специализированная система для анализа документов и табличных структур.

В LLaVA изображение сначала приводится к фиксированному разрешению, например 336×336 , после чего разбивается на патчи и обрабатывается visual encoder-ом. Для обычных изображений такого разрешения часто достаточно,

однако таблицы являются более сложным объектом. Они содержат много мелких элементов: текст внутри ячеек, тонкие границы, отступы, выравнивание, цветовые выделения, объединённые ячейки и многоуровневые заголовки. [8, 9]

Если изображение таблицы уменьшается до фиксированного размера, часть этой информации может быть потеряна. Например, тонкие границы ячеек могут стать почти невидимыми, мелкий текст — плохо различимым, а расстояния между строками и столбцами — менее информативными. В результате модель может корректно распознать отдельные слова или числа, но ошибиться при восстановлении структуры таблицы.

Важно отметить, что для таблиц недостаточно выполнить только OCR. OCR отвечает на вопрос: какой текст находится на изображении. Однако понимание таблицы требует восстановления двумерной структуры. Модель должна определить, какие значения находятся в одной строке, какие относятся к одному столбцу, где расположены заголовки и есть ли объединённые ячейки. [2, 4]

Если visual encoder потерял информацию о структуре ещё на этапе кодирования изображения, языковая модель уже не сможет полностью восстановить её на этапе генерации ответа.

2.3.3 Qwen2.5-VL как пример развития VLM-архитектур

Ключевое отличие Qwen2.5-VL от базовых LLaVA-подобных моделей заключается в использовании динамического разрешения. Это означает, что модель не обязана приводить каждое изображение к одному фиксированному размеру. Вместо этого она может работать с изображениями разного разрешения и сохранять больше визуальных деталей. [7]

В случае таблиц это особенно заметно: если таблица большая или содержит много мелких ячеек, грубое сжатие изображения может разрушить её структуру. Динамическое разрешение уменьшает эту проблему, так как помогает сохранить:

1. мелкий текст;
2. границы ячеек;
3. расстояния между строками и столбцами;
4. цветовые выделения;
5. расположение заголовков;
6. визуальную группировку данных.

В technical report для Qwen2.5-VL указано, что модель способна работать с документами, таблицами, формами и диаграммами, а также использовать динамическое разрешение для сохранения большего числа визуальных деталей. Поэтому её можно использовать как сильную универсальную baseline-модель для проверки того, насколько VLM общего назначения справляется с восстановлением таблицы по изображению. [7]

2.3.4 Проблема дорогого attention при увеличении разрешения

Динамическое разрешение помогает сохранить больше информации об изображении, но вместе с этим увеличивает вычислительную нагрузку. Чем выше разрешение изображения, тем больше визуальных токенов получает модель.

Обычный механизм self-attention сравнивает каждый токен с каждым, поэтому его вычислительная сложность растёт квадратично относительно числа токенов. Например, если увеличить изображение в два раза по высоте и ширине, количество токенов возрастёт примерно в четыре раза, а стоимость attention — примерно в шестнадцать раз. [9]

Для таблиц возникает противоречие. С одной стороны, высокое разрешение необходимо, чтобы сохранить мелкий текст, тонкие границы ячеек, отступы и выравнивание. С другой стороны, большое число токенов делает обработку изображения более дорогой по памяти и времени.

Qwen2.5-VL снижает эту проблему за счёт Window Attention. В отличие от полного attention, где каждый токен сравнивается со всеми остальными токенами изображения, Window Attention вычисляет внимание внутри локальных областей изображения. [7]

Для таблиц такой подход хорошо подходит, потому что многие признаки структуры имеют локальный характер: границы ячейки, текст внутри неё, соседние строки, соседние столбцы, отступы и выравнивание. За счёт этого модель может обрабатывать крупные изображения таблиц эффективнее, не отказываясь от большого количества визуальных деталей.

2.3.5 GLM-OCR в качестве примера специализированной OCR-модели для документов

GLM-OCR была разработана конкретно под задачи визуального распознавания документов и извлечение ключевых признаков. Модель обладает эталонной производительностью при всего 0.9B параметров, благодаря уникальной комплексной архитектуре. [6]

1. **Layout Detector / Region Cropper.** Сначала система анализирует страницу и находит отдельные области: абзацы, таблицы, формулы. Это делает PPDocLayoutV3 на уровне sdk. Идея: не давать модели сразу всю сложную страницу, а разбить её на более простые куски. Так меньше галлюцинаций, меньше повторов и проще сохранить порядок чтения. [13]
2. **Vision Encoder — CogViT,** около 400M параметров. Он берёт изображение или вырезанный регион и превращает его в набор визуальных эмбеддингов. [6]
3. **Cross-modal connector.** Лёгкий connector, переводящий визуальные признаки из encoder'а в пространство языковой модели.

4. **LLM Decoder — GLM**, около 500M параметров. Это авторегрессионная языковая модель: она генерирует ответ токен за токеном, опираясь на визуальные эмбединги и текстовые инструкции.
5. **MTP — Multi-Token Prediction**. Обычная LLM генерирует один токен за шаг. GLM-OCR добавляет несколько вспомогательных голов, которые позволяют предсказывать сразу несколько следующих токенов. Это ускоряет работу decoder блока и помогает лучше сохранять локальную структуру [6]




Figure 2 Схема модели GLM-OCR

Глава 3. Экспериментальная установка

3.1 Набор данных

В экспериментальной части использовалась фиксированная подвыборка таблиц из PubTabNet. PubTabNet представляет собой крупный датасет для задачи распознавания табличной структуры: для каждой таблицы в нём доступно изображение и соответствующее эталонное HTML-представление. Такой формат удобен для оценки моделей, поскольку позволяет сравнивать сгенерированную моделью HTML-разметку с правильной структурой таблицы. [4]

В ходе исследования использовался набор из 50 таблиц: 25 простых и 25 сложных. К сложным относились таблицы, содержащие объединённые ячейки; простые таблицы таких ячеек не содержали. Кандидаты для включения в выборку были отобраны случайным образом. После этого был проведён ручной просмотр таблиц, чтобы убедиться, что они достаточно различаются по структуре и визуальным характеристикам и подходят для анализа устойчивости моделей.

Для проверки устойчивости моделей к визуальному оформлению каждая таблица была отрендерена в нескольких CSS-стилях. Всего использовалось семь вариантов оформления:

1. `baseline` — контрольный стиль с обычной табличной сеткой: чёткие границы ячеек, центрирование текста и стандартный sans-serif шрифт;
2. `column_bands` — стиль без сетки, где структура подчёркивается чередованием фона по столбцам; он позволяет проверить, может ли модель восстановить колонки не по линиям, а по цветовым вертикальным областям;
3. `left_aligned_compact` — компактная таблица с уменьшенным шрифтом, плотными отступами и выравниванием текста влево; этот стиль проверяет зависимость модели от привычного центрирования текста в таблицах;
4. `no_grid_whitespace` — таблица без границ ячеек, где структура задаётся только пробелами, отступами и выравниванием; он проверяет, способна ли модель восстановить таблицу без явной сетки;
5. `no_grid_zebra` — таблица без сетки, но с чередующимся фоном строк; этот стиль позволяет проверить, помогает ли визуальное разделение строк восстановить структуру таблицы без линий;
6. `serif_paper_style` — стиль, похожий на таблицы из научных статей: serif-шрифт, горизонтальные линии и отсутствие вертикальных границ; он проверяет устойчивость модели к академическому оформлению таблиц;
7. `weak_grid_dense` — плотная таблица с маленьким шрифтом, тонкими слабыми границами и минимальными отступами; этот стиль показывает, как модель справляется с мелким текстом и слабовыраженной сеткой.

Таким образом, для каждой модели и конфигурации было получено 350 изображений: 50 таблиц, отрендеренных в семи стилях.

Пример простой таблицы:

Group	Variable	Lambda	F	DF1	DF2	p-value
SD-Risk	IFN	0.4841	17.5871	2	33	< 0.0001
SD-Risk	IL-2	0.3719	27.8637	2	33	< 0.0001
SD-Risk	IL-10	0.6091	10.5889	2	33	0.0003
Treatment	IFN	0.7142	5.6031	2	28	0.0090
Treatment	IL-2	0.6751	6.7385	2	28	0.0041

Пример сложной таблицы:

Variable		CTX only		Trastuzumab + CTX		Total		P-value
Number of patients		45		70		115		
Gender								
	Male	34	75.6%	52	74.3%	86	74.8%	0.878
	Female	11	24.4%	18	25.7%	29	25.2%	
Age								
	Median age, years (range)	58 (37–72)		59 (30–80)		58 (30–80)		0.884*
BMI								
	Median, kg/m ² (range)	22.7 (16.7–35.0)		21.4 (13.8–32.5)		21.9 (13.8–35.0)		0.059*
Baseline LVEF								
	Median, % (range)	66 (57–75)		65 (57–75)		66 (57–75)		0.307*
Maximally decreased LVEF from baseline LVEF								
	Median, % (range)	6 (1–12)		7 (1–21)		6 (1–21)		0.279*
Total treatment cycles								
	Median, number (range)	8 (2–92)		9 (1–62)		8 (1–92)		0.827*
Hypertension								
	Yes	12	26.7%	18	25.7%	30	26.1%	0.910
	No	33	73.3%	52	74.3%	85	73.9%	
Underlying cardiac disease								
	Yes	1	2.2%	3	4.3%	4	3.5%	>0.99†
	No	44	97.8%	67	95.7%	111	96.5%	
Diabetes								
	Yes	5	11.1%	8	11.4%	13	11.3%	>0.99†
	No	40	88.9%	62	88.6%	102	88.7%	
Hyperlipidemia								
	Yes	0	0.0%	2	2.8%	2	1.7%	0.519†
	No	45	100%	68	97.2%	113	98.3%	
Cerebrovascular disease								
	Yes	1	2.2%	3	4.3%	4	3.5%	>0.99†
	No	44	97.8%	67	95.7%	111	96.5%	
Smoking								
	Current	15	33.3%	20	28.6%	35	30.4%	0.862
	Former	11	24.4%	18	25.7%	29	25.2%	
	Never	19	42.3%	32	45.7%	51	44.4%	

3.2 Подсчет метрики

Для оценки качества восстановления таблиц использовалась метрика TEDS — *Tree-Edit-Distance-based Similarity*. Эта метрика была предложена в работе Image-based Table Recognition: Data, Model, and Evaluation вместе с датасетом PubTabNet и предназначена специально для оценки качества распознавания HTML-структуры таблицы. [4]

Основная идея TEDS заключается в том, что HTML-таблица рассматривается не просто как строка текста, а как дерево. В этом дереве узлами являются элементы HTML-разметки: table, thead, tbody, tr, td и другие теги. Предсказанная моделью таблица и эталонная таблица из PubTabNet преобразуются в такие деревья, после чего между ними считается расстояние редактирования деревьев. [4, 5]

Tree Edit Distance показывает, сколько операций нужно выполнить, чтобы превратить предсказанное дерево в эталонное. К таким операциям относятся добавление, удаление и замена узлов. Чем меньше требуется изменений, тем ближе предсказанная таблица к правильной. Затем расстояние нормализуется, поэтому итоговое значение TEDS лежит в диапазоне от 0 до 1. [5]

В работе использовались два варианта метрики:

TEDS full — учитывает как структуру таблицы, так и содержимое ячеек. В этом режиме модель штрафует не только за ошибки в строках, столбцах, rowspan и colspan, но и за неправильное распознавание текста внутри ячеек

TEDS structure-only — учитывает только структуру таблицы. Содержимое ячеек игнорируется, поэтому эта версия метрики показывает, насколько хорошо модель восстановила именно табличную разметку: строки, столбцы, ячейки и объединения

Реализация TEDS была взята из официального репозитория PubTabNet. В данной работе предсказанный моделью HTML сравнивался с эталонным HTML из PubTabNet. Для каждого изображения вычислялись значения TEDS full и TEDS structure-only [4]

3.3 Формат проведения испытаний

Для каждого изображения модели подавалась инструкция восстановить таблицу в формате HTML. Полученный ответ очищался от лишнего текста и сравнивался с эталонной HTML-разметкой из PubTabNet. Для каждого визуального стиля результаты сохранялись отдельно, после чего вычислялись средние значения TEDS full и TEDS structure-only.

Исходный код, использованный для подготовки данных, инференса моделей, нормализации HTML-разметки, подсчёта метрик и построения визуализаций, размещён в открытом репозитории: <https://github.com/sakuta02/visual-table-understanding>.

Глава 4. Исследование

4.1 Общие результаты


Model	Resolution	Style	TEDS full	TEDS structure	Simple structure	Complex structure	Avg time, s
GLM-OCR	1400x2048	baseline	0.838	0.966	0.976	0.956	31.29
GLM-OCR	1400x2048	weak_grid_dense	0.812	0.929	0.938	0.920	26.02
GLM-OCR	1400x2048	column_bands	0.820	0.950	0.970	0.930	30.66
GLM-OCR	1400x2048	no_grid_zebra	0.823	0.950	0.966	0.933	30.94
GLM-OCR	1400x2048	no_grid_whitespace	0.812	0.941	0.951	0.932	33.83
GLM-OCR	1400x2048	serif_paper_style	0.818	0.931	0.951	0.912	29.53
GLM-OCR	1400x2048	left_aligned_compact	0.816	0.936	0.921	0.950	29.27
GLM-OCR	900x2048	baseline	0.797	0.926	0.904	0.949	32.08
GLM-OCR	900x2048	weak_grid_dense	0.758	0.876	0.848	0.903	29.98
GLM-OCR	900x2048	column_bands	0.796	0.926	0.916	0.935	32.45
GLM-OCR	900x2048	no_grid_zebra	0.798	0.923	0.936	0.911	31.61
GLM-OCR	900x2048	no_grid_whitespace	0.791	0.927	0.926	0.929	32.32
GLM-OCR	900x2048	serif_paper_style	0.784	0.900	0.908	0.891	31.18
GLM-OCR	900x2048	left_aligned_compact	0.784	0.908	0.875	0.941	29.98
Qwen	1400x2048	baseline	0.753	0.868	0.888	0.847	54.45
Qwen	1400x2048	weak_grid_dense	0.741	0.859	0.867	0.851	50.10
Qwen	1400x2048	column_bands	0.745	0.861	0.884	0.839	53.13
Qwen	1400x2048	no_grid_zebra	0.732	0.848	0.860	0.835	54.24
Qwen	1400x2048	no_grid_whitespace	0.720	0.827	0.834	0.821	53.17
Qwen	1400x2048	serif_paper_style	0.742	0.853	0.864	0.842	53.96
Qwen	1400x2048	left_aligned_compact	0.751	0.876	0.892	0.861	54.38
Qwen	900x2048	baseline	0.702	0.815	0.809	0.820	62.44
Qwen	900x2048	weak_grid_dense	0.675	0.796	0.760	0.831	58.87
Qwen	900x2048	column_bands	0.695	0.818	0.814	0.823	59.97
Qwen	900x2048	no_grid_zebra	0.702	0.826	0.828	0.825	57.55
Qwen	900x2048	no_grid_whitespace	0.663	0.788	0.777	0.799	59.41
Qwen	900x2048	serif_paper_style	0.696	0.816	0.798	0.834	63.33
Qwen	900x2048	left_aligned_compact	0.704	0.830	0.814	0.846	58.04

GLM-OCR показала себя лучше, чем Qwen, в задаче распознавания табличных данных. Даже наиболее слабая конфигурация GLM-OCR превзошла наиболее сильную конфигурацию Qwen по TEDS full и TEDS structure: 900 пикселей у GLM-OCR против 1400 пикселей у Qwen. При этом у каждой из конфигураций не наблюдается явного перекоса между результатами TEDS structure для simple и complex таблиц. Это означает, что наличие merged cells не стало фактором, который сильно меняет качество восстановления структуры для рассматриваемых моделей. Отдельно стоит отметить стиль no_grid_zebra: при низком разрешении изображения он показал высокий результат у обеих моделей. Вероятно, это связано с тем, что при понижении разрешения границы таблицы становятся менее чёткими и могут мешать распознаванию, тогда как цветное выделение ячеек остаётся более заметным визуальным признаком. В более сильных конфигурациях этот стиль уже уступает вариантам с явными границами:

при большем разрешении моделям проще восстанавливать структуру по линиям таблицы, а не по цветовой разметке.


По полному TEDS влияние стиля оказалось умеренным: внутри каждой конфигурации разница между худшим и лучшим стилем находится в диапазоне примерно от 3.2% до 6.1%. Наименьший разброс наблюдается у GLM-OCR 1400x2048 — 3.21%, что говорит о большей устойчивости этой конфигурации к изменению визуального оформления таблицы. Наибольший разброс оказался у Qwen 900x2048 — 6.14%, где выбор стиля заметнее влияет на качество распознавания. В абсолютных значениях максимальные различия составляют около 0.026–0.041 пункта TEDS. То есть влияние стиля есть, но оно заметно меньше различий между самими моделями.

При этом Qwen оказался более медленным при восстановлении HTML-структуры таблицы. Это может быть связано с различиями в архитектуре и назначении моделей. GLM-OCR является специализированной OCR-моделью, а её decoder использует multi-token prediction, что позволяет предсказывать несколько токенов за один шаг и сокращать время генерации. В среднем GLM-OCR выполняет инференс на 28.57с быстрее, чем Qwen, при разрешении 900 пикселей и на 23.13с быстрее при разрешении 1400 пикселей. При переходе от 900 к 1400 пикселям время инференса уменьшилось у обеих моделей: у Qwen примерно на 10.99%, у GLM-OCR — на 3.67%. Более заметное изменение у Qwen может быть связано с большей зависимостью модели от качества входного изображения и длины генерируемой HTML-последовательности. GLM-OCR, как специализированная OCR-модель, показывает более устойчивое время работы при изменении разрешения



4.2 Основные сложности, анализ хитмапов

4.2.1 GLM-OCR




Наиболее сложной таблицей для OCR-модели оказалась таблица под номером 7. На хитмапах видно, что для этого изображения TEDS full резко падает почти во всех стилях, особенно при разрешении 900 пикселей. Это связано с формой самой таблицы: она сильно вытянута по горизонтали, содержит несколько широких столбцов и длинные текстовые описания. При уменьшении изображения такая таблица превращается в плотную узкую полосу, где текст и границы ячеек становятся плохо различимыми.

При повышении разрешения до 1400 пикселей качество в целом улучшается, но для стилей `no_grid_whitespace` и `left_aligned_compact` заметного прироста не происходит. Вероятно, в этих вариантах модели не хватает явных визуальных границ между ячейками. В `no_grid_whitespace` структура задаётся в основном отступами, а в `left_aligned_compact` элементы расположены слишком плотно. Поэтому увеличение разрешения помогает лучше видеть текст, но не полностью решает проблему восстановления строк и столбцов.

Второй по сложности оказалась таблица под номером 2. По визуальной структуре она близка к таблице 7: также сильно вытянута по горизонтали, содержит несколько столбцов и длинные текстовые фрагменты. Однако при повышении разрешения текст в ней становится более различимым, чем в предыдущем случае, поэтому падение качества оказывается менее выраженным. Это показывает, что для GLM-OCR такие широкие и плотные таблицы остаются сложными, но увеличение разрешения может частично улучшать восстановление структуры, если текст и границы ячеек становятся читаемее.


4.2.2 Qwen



Для Qwen крайне проблемной при разрешении 900 пикселей оказалась таблица под номером 1. На хитмапе видно, что для этого изображения TEDS structure резко падает сразу в нескольких стилях, тогда как при повышении разрешения до 1400 пикселей проблема в основном исчезает. По визуальной структуре эта таблица схожа с номером 7: она сильно вытянута по горизонтали, содержит несколько широких столбцов и длинные текстовые описания.

В отличие от GLM-OCR, для Qwen таблица под номером 2 оказалась менее проблемной: даже при низком разрешении её структура восстанавливается лучше, чем у OCR-модели. Однозначно объяснить это различие сложно, поскольку визуально таблица относится к тому же типу сложных широких таблиц с длинными текстовыми ячейками. Вероятнее всего, этот случай можно рассматривать как отдельный выброс, связанный с особенностями конкретного изображения, ответа модели или тем, как Qwen обработал именно эту таблицу.

4.2.3 Сравнение моделей



На разностном хитмапе показана величина GLM-OCR score – Qwen score для структурного TEDS. В целом на обоих разрешениях преобладают красные области, что подтверждает более высокое качество восстановления структуры у GLM-OCR по сравнению с Qwen.

При разрешении 900 пикселей преимущество GLM-OCR выражено особенно заметно: есть несколько вертикальных участков, где положительная разница сохраняется сразу для нескольких стилей. При переходе к 1400 пикселям часть этих различий ослабевает, то есть повышение разрешения помогает Qwen частично сократить отставание. Однако общий характер хитмапа сохраняется: GLM-OCR чаще показывает более высокий структурный TEDS. Отдельные синие ячейки указывают на случаи, где Qwen лучше справляется с конкретной таблицей или стилем, но они выглядят как локальные исключения, а не как общий тренд.

Заключение

В ходе работы была достигнута поставленная цель: проведён анализ устойчивости мультимодальных языковых моделей к изменению графического оформления сложных таблиц, включая линовку, цветовое кодирование и форматирование ячеек.

Для этого был сформирован тестовый набор на основе PubTabNet. В него вошли 50 таблиц: 25 простых таблиц без объединённых ячеек и 25 сложных таблиц с merged cells. Каждая таблица была отрендерена в семи CSS-стилях, что позволило проверить не только общее качество моделей, но и их чувствительность к изменению внешнего вида таблицы. Также был реализован программный модуль для инференса GLM-OCR и Qwen2.5-VL, сохранения предсказаний, нормализации HTML-разметки и подсчёта метрики TEDS. После этого был проведён сравнительный анализ моделей при разных разрешениях входного изображения.

По результатам экспериментов GLM-OCR показала более высокое качество восстановления таблиц, чем Qwen2.5-VL. Даже при меньшем разрешении изображения конфигурация GLM-OCR 900x2048 превзошла Qwen 1400x2048 по средним значениям TEDS full и TEDS structure. Это показывает, что в данной задаче специализация модели на OCR и обработке документов оказалась важнее, чем одно только увеличение разрешения входного изображения.

Влияние визуального стиля таблицы оказалось заметным, но не определяющим. Различия между стилями внутри одной конфигурации были меньше, чем различия между самими моделями. При низком разрешении хорошо проявил себя стиль `no_grid_zebra`, поскольку цветовое выделение строк остаётся различимым даже тогда, когда границы таблицы становятся менее чёткими. При более высоком разрешении преимущество чаще получали стили с явными линиями, так как модели могли использовать границы ячеек для восстановления структуры.

Анализ хитмапов показал, что наиболее сложными для моделей оказались широкие таблицы с длинными текстовыми описаниями. При уменьшении изображения такие таблицы становятся плотными и плохо читаемыми: текст, границы и расстояния между ячейками теряют различимость. В этих случаях ошибка связана не только с распознаванием текста, но и с восстановлением соответствия между строками, столбцами и отдельными ячейками. Для Qwen2.5-VL также было заметно, что повышение разрешения сильнее влияет на качество результата, однако этого оказалось недостаточно, чтобы стабильно превзойти специализированную OCR-модель.

По времени инференса GLM-OCR также оказалась быстрее. В среднем она выполняла генерацию HTML-разметки быстрее Qwen как при разрешении 900 пикселей, так и при разрешении 1400 пикселей. Это может быть связано с более

узкой специализацией модели и использованием multi-token prediction в decoder-блоке.

Таким образом, проведённое исследование показало, что современные мультимодальные модели могут применяться для восстановления таблиц по изображению, однако в задаче восстановления HTML-структуры специализированная OCR-модель оказалась более устойчивой и эффективной.

Список литературы

- [1] Wu X., Ritter A., Xu W. Tabular Data Understanding with LLMs: A Survey of Recent Advances and Challenges. arXiv, 2025. <https://arxiv.org/abs/2508.00217>
- [2] Kasem M. S., Abdallah A., Berendeyev A., Elkady E., Mahmoud M., Abdalla M., Hamada M., Vascon S., Nurseitov D., Taj-Eddin I. Deep Learning for Table Detection and Structure Recognition: A Survey. ACM Computing Surveys, 2024. <https://doi.org/10.1145/3657281> <https://arxiv.org/abs/2211.08469>
- [3] Fang X., Xu W., Tan F. A., Zhang J., Hu Z., Qi Y., Nickleach S., Socolinsky D., Sengamedu S., Faloutsos C. Large Language Models (LLMs) on Tabular Data: Prediction, Generation, and Understanding — A Survey. arXiv, 2024. <https://arxiv.org/abs/2402.17944>
- [4] Zhong X., ShafieiBavani E., Jimeno-Yepes A. Image-based Table Recognition: Data, Model, and Evaluation. arXiv, 2019. <https://arxiv.org/abs/1911.10683>
- [5] Pawlik M., Augsten N. RTED: A Robust Algorithm for the Tree Edit Distance. arXiv, 2011. <https://arxiv.org/abs/1201.0230>
- [6] Duan S. et al. GLM-OCR Technical Report. arXiv, 2026. <https://arxiv.org/abs/2603.10910>
- [7] Bai S. et al. Qwen2.5-VL Technical Report. arXiv, 2025. <https://arxiv.org/abs/2502.13923>
- [8] Liu H., Li C., Li Y., Lee Y. J. Improved Baselines with Visual Instruction Tuning. arXiv, 2023. <https://arxiv.org/abs/2310.03744>
- [9] Dosovitskiy A., Beyer L., Kolesnikov A., Weissenborn D., Zhai X., Unterthiner T., Dehghani M., Minderer M., Heigold G., Gelly S., Uszkoreit J., Houlsby N. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. arXiv, 2020. <https://arxiv.org/abs/2010.11929>
- [10] Radford A., Kim J. W., Hallacy C., Ramesh A., Goh G., Agarwal S., Sastry G., Askell S., Mishkin P., Clark J., Krueger G., Sutskever I. Learning Transferable Visual Models From Natural Language Supervision. arXiv, 2021. <https://arxiv.org/abs/2103.00020>
- [11] Liu H., Li C., Wu Q., Lee Y. J. Visual Instruction Tuning. arXiv, 2023. <https://arxiv.org/abs/2304.08485>
- [12] Chiang W.-L., Li Z., Lin Z., Sheng Y., Wu Z., Zhang H., Zheng L., Zhuang S., Zhuang Y., Gonzalez J. E., Stoica I., Xing E. P. Vicuna: An Open-Source Chatbot Impressing GPT-4 with 90% ChatGPT Quality. LMSYS Blog, 2023. <https://lmsys.org/blog/2023-03-30-vicuna/>
- [13] Cui C., Sun T., Lin M. et al. PaddleOCR 3.0 Technical Report. arXiv, 2025. <https://arxiv.org/abs/2507.05595>

- [14] Majumder B. P., Surana H., Agarwal D., Mishra B. D., Meena A., Prakhar A., Vora T., Khot T., Sabharwal A., Clark P. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. arXiv, 2024. <https://arxiv.org/abs/2407.01725>
- [15] Lei F., Chen J., Ye Y., Cao R., Shin D., Su H., Suo Z., Gao H., Hu W., Yin P., Zhong V., Xiong C., Sun R., Liu Q., Wang S., Yu T. Spider 2.0: Evaluating Language Models on Real-World Enterprise Text-to-SQL Workflows. arXiv, 2024. <https://arxiv.org/abs/2411.07763>
- [16] Zhao Y., Qi Z., Nan L., Mi B., Liu Y., Zou W., Han S., Chen R., Tang X., Xu Y., Radev D., Cohan A. QTSumm: Query-Focused Summarization over Tabular Data. arXiv, 2023. <https://arxiv.org/abs/2305.14303>
- [17] Zhang H., Cao R., Chen L., Xu H., Yu K. ACT-SQL: In-Context Learning for Text-to-SQL with Automatically-Generated Chain-of-Thought. arXiv, 2023. <https://arxiv.org/abs/2310.17342>
- [18] Zheng M., Feng X., Si Q., She Q., Lin Z., Jiang W., Wang W. Multimodal Table Understanding. arXiv, 2024. <https://arxiv.org/abs/2406.08100>